

Hands-on Deep Learning - Aula 1

Introdução, Ambiente Computacional e Shallow Learning

Hugo Oliveira¹², Camila Laranjeira²³

¹Instituto de Matemática e Estatística (IME)
Universidade de São Paulo

²Interest Group in Pattern Recognition and Earth Observation (PATREO)
Universidade Federal de Minas Gerais

³Programa de Pós-Graduação em Ciência da Computação (PPGCC)
Universidade Federal de Minas Gerais

16 de Abril, 2021



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network

Material



- Hugo Oliveira²



- Camila Laranjeira¹



¹ <http://homepages.dcc.ufmg.br/~oliveirahugo/>

² <http://homepages.dcc.ufmg.br/~camilalaranjeira/>



Objetivos do Curso

- Introduzir os conceitos básicos de aprendizado profundo usando redes neurais artificiais
- Apresentar ferramentas, *frameworks* e ambientes de programação para desenvolvimento de soluções com *Deep Learning*
- **Introduzir técnicas consolidadas e exercitar na prática formas de adaptação para outros problemas**

Ementa



- Aula 1

- Boas Vindas
- Ambiente
- Python & bibliotecas
- Machine Learning
- Redes Neurais

- Aula 2

- Fundamentos de Redes Neurais
- MultiLayer Perceptrons (MLPs)
- Classificação de Imagens usando MLPs

Ementa do Curso



- Aula 3

- Redes Neurais Convolucionais (CNNs)
- Segmentação
- Detecção

- Aula 4

- Redes Recorrentes (RNNs)

- Aula 5

- Redes Generativas

- Aula 6

- Conclusão
- Desafio Final



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features


4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



Introdução a Deep Learning



Since an early flush of optimism in the 1950s, smaller subsets of artificial intelligence – first machine learning, then deep learning, a subset of machine learning – have created ever larger disruptions.

Figura: Ilustrando a relação entre Deep Learning, Aprendizado de Máquina e Inteligência Artificial [1]



O que é Aprendizado de Máquina?

Definição Abstrata⁶

Um algoritmo capaz de aprender com a experiência, nos permitindo lidar com tarefas muito difíceis para serem solucionadas com algoritmos explicitamente programados por seres humanos.

Definição Prática

Um algoritmo parametrizado, capaz de encontrar o conjunto de parâmetros que melhor se aproxima do comportamento desejado.

⁶ Ian Goodfellow, Yoshua Bengio, and Aaron Courville. Deep Learning. MIT Press, 2016. <http://www.deeplearningbook.org>



O que motivou Deep Learning?

- O mundo real **não é estruturado**
- Dados do mundo real possuem uma **alta variabilidade**
- Um **desafio para a Inteligência Artificial** é aprender representações e modelos capazes de lidar com tais adversidades



O que motivou Deep Learning?




Figura: Exemplo de aplicação onde o dado possui diferentes variações.



O que motivou Deep Learning?





Figura: Diferença entre Aprendizado de Máquina tradicional e Deep Learning.



O que é Deep Learning?

- Tipo de Aprendizado de Máquina
- Baseado em Redes Neurais profundas
 - Mais de uma camada escondida
- Vasta gama de aplicações e **variações do modelo neural**





“Zoológico” de Arquiteturas

A mostly complete chart of Neural Networks

©2016 Fjodor van Veen - aimovx.institute.org

- ⦿ Backfed Input Cell
- Input Cell
- △ Noisy Input Cell
- Hidden Cell
- ⦿ Probabilistic Hidden Cell
- ⦿ Spiking Hidden Cell
- Output Cell
- Match Input Output Cell
- Recurrent Cell
- Memory Cell
- ⦿ Different Memory Cell
- Kernel
- Convolution or Pool

Deep Feed Forward (DFF)



Perceptron (P)



Feed Forward (FF)



Radial Basis Network (RBF)




Deep Convolutional Network (DCN)



Deconvolutional Network (DN)



Deep Convolutional Inverse Graphics Network (DCIGN)



Recurrent Neural Network (RNN)



Long / Short Term Memory (LSTM)



Gated Recurrent Unit (GRU)



Auto Encoder (AE)



Variational AE (VAE)




Denoising AE (DAE)



Sparse AE (SAE)



Generative Adversarial Network (GAN)



Liquid State Machine (LSM)



Extreme Learning Machine (ELM)



Echo State Network (ESN)



Markov Chain (MC)



Hopfield Network (HN)




Boltzmann Machine (BM)




Restricted BM (RBM)



Deep Belief Network (DBN)



Deep Residual Network (DRN)



Kohonen Network (KN)



Support Vector Machine (SVM)



Neural Turing Machine (NTM)





O que é Deep Learning?

- Num geral, Deep Learning é um técnica de aprendizado de máquina voltada para redes neurais artificiais que aprendem a extrair informações de diferentes níveis de abstração observando diretamente o dado
 - Baixo-nível, como bordas e cantos em imagens
 - Médio-nível, partes inteiras de objetos, como um nariz ou uma boca
 - Alto-nível, que representa todo o objeto como, por exemplo, um rosto



O que é Deep Learning?




Figura: Exemplo [2] mostrando como Deep Learning parte de representações simples para mais complexas




Aplicações


- Transferência de Estilo



- Recomendação de conteúdo




- Classificação



Aplicações




- Carros Autônomos



- Vigilância



- Imagens Médicas





O que é Deep Learning

Importância do Deep Learning

É difícil compreender a importância do avanço tecnológico que representa a chegada do Deep Learning sem explicar como funciona Shallow Learning



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



Ambiente Computacional

- Python
 - Linguagem e biblioteca padrão
- Anaconda
 - Gerenciador de pacotes e ambientes
- Jupyter
 - Ambiente de programação, plots e anotações
- Pytorch
 - Framework de processamento vetorial e Deep Learning
- Colaboratory
 - Serviço de Cloud Gratuito da Google

Python⁷



- Linguagem interpretada
- Pensada para prototipação rápida
- Alta legibilidade
- *Binds* simples com outras linguagens
- Funciona em várias plataformas
- Fortemente e dinamicamente tipada

⁷ <https://www.python.org/>

Python⁷



- Vasta biblioteca padrão
- Bibliotecas externas incluem uma vasta gama de aplicações computacionais
 - Processamento vetorial (Numpy)
 - Processamento científico (Scipy)
 - Visualização de dados (matplotlib)
 - Processamento de imagens (Scikit-Image)
 - Machine Learning (Scikit-Learn)
 - Deep Learning (Pytorch, Tensorflow, Theano, Caffe...)

⁷ <https://www.python.org/>

Anaconda⁸



- Gerenciador de pacotes relacionados ao Python
- Já vem com vários pacotes importantes para programação científica
 - Numpy, Scipy, Scikit-Image, Scikit-Learn, matplotlib, Jupyter...
- Ambientes virtuais

⁸<https://anaconda.org/anaconda/python>

Jupyter⁹



- IDE de acesso via browser
- Visualização em tempo de execução de plots, imagens, anotações...
- Funções custom do IPython
- Acesso direto às documentações das bibliotecas

⁹ <http://jupyter.org/>

Pytorch¹⁰



- Framework de Machine Learning focado em Deep Learning
- Implementação baseada no Torch (em Lua)
- Comunidade grande e participativa
 - Muitos modelos implementados pela comunidade podem ser encontrados na internet
- Possui várias funcionalidades úteis (i.e. Data Loader, Agendador de Learning Rate, Data Augmentation...)

¹⁰<https://pytorch.org/>

Google Colaboratory¹¹



- Construído em cima do Jupyter
- Serviço de Cloud gratuito para desenvolvimento de I.A.
- Tesla K80 GPU disponível por até 12 horas contínuas
- Permite diferentes frameworks (Keras, Tensorflow, Pytorch)

¹¹ <https://colab.research.google.com/>



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network

Estruturas de Dados Básicas



- Listas (*lists*)
- Tuplas (*tuples*)
- Conjuntos (*sets*)
- Dicionários (*dictionaries*)

Cheat Sheet Python Basics

[illegible]

Figura: Cheat Sheet de funções básicas do Python¹².



Estruturas de Dados Básicas

Demo - Python Collections

Collections_Python.ipynb



Introdução ao Numpy/Scipy

- Operações vetoriais/matriciais em Python
- Base para a maioria do Python Científico
- Funções que cobrem uma vasta gama de operações vetoriais

Cheat Sheet Numpy



Python For Data Science Cheat Sheet

Numpy Basics

Learn Python for Data Science interactively at datacamp.com



Numpy

The Numpy library is the core library for scientific computing in Python. It provides a high-performance multidimensional array object, and tools for working with these arrays.

Use the following import convention:

```
import numpy as np
```



Numpy Arrays

1D array



2D array



3D array



Creating Arrays

```
np.zeros(10) # Create an array of zeros
np.ones(10) # Create an array of ones
np.full(10, 7) # Create an array of 10 sevens
```

Initial Placeholders

```
np.empty(10) # Create an array of 10 uninitialized values
np.empty_like(x) # Create an array of the same shape and dtype as x, but uninitialized
```

Initial Placeholders

```
np.empty(10) # Create an array of 10 uninitialized values
np.empty_like(x) # Create an array of the same shape and dtype as x, but uninitialized
```

I/O

Saving & Loading On Disk

```
np.save('array.npy', x) # Save array x to file array.npy
np.load('array.npy') # Load array from file array.npy
```

Saving & Loading Text Files

```
np.savetxt('array.txt', x, delimiter=',') # Save array x to file array.txt
np.loadtxt('array.txt', delimiter=',') # Load array from file array.txt
```

Data Types

```
np.float64 # 64-bit floating point
np.float32 # 32-bit floating point
np.complex64 # 64-bit complex number
np.int64 # 64-bit integer
np.int32 # 32-bit integer
np.bool_ # Boolean type
np.str_ # String type
np.object_ # Object type
```

Inspecting Your Array

```
arr.ndim # Array dimensions
arr.size # Length of array
arr.dtype # Data type of array elements
arr.itemsize # Size of one array element in bytes
arr.nbytes # Total bytes of the array
```

Arithmetic Operations

```
arr + arr # Addition
arr - arr # Subtraction
arr * arr # Multiplication
arr / arr # Division
```

Array Mathematics

```
arr.mean() # Mean
arr.std() # Standard deviation
arr.var() # Variance
```

```
arr.min() # Minimum
arr.max() # Maximum
```

```
arr.argmax() # Index of maximum element
arr.argmin() # Index of minimum element
```

```
arr.sum() # Sum
arr.prod() # Product
```

```
arr.cumsum() # Cumulative sum
arr.cumprod() # Cumulative product
```

```
arr.sort() # Sort
arr.argsort() # Indices that would sort the array
```

```
arr.partition(kth) # Partition the array
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

```
arr.sort() # Sort
arr.sort() # Sort
```

Subsetting, Slicing, Indexing

Also see Lists

```
arr[0] # First element
arr[1] # Second element
arr[2] # Third element
```

```
arr[0:2] # Elements from index 0 to 1
arr[2:] # Elements from index 2 to the end
```

```
arr[:2] # Elements from the beginning to index 1
arr[-2:] # Last two elements
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

```
arr[0:2, 0:2] # First 2x2 subarray
arr[0:2, 2:] # First 2x2 subarray
```

```
arr[:, 0:2] # First two columns
arr[:, 2:] # All columns except the first two
```

```
arr[0, 0:2] # First row, first two columns
arr[2, 0:2] # Third row, first two columns
```

Figura: Cheat Sheet de funções do Numpy¹³.

Cheat Sheet Scipy



Python For Data Science Cheat Sheet

SciPy - Linear Algebra

Learn More Python for Data Science <https://www.datacamp.com>

SciPy

The SciPy library is one of the core packages for scientific computing that provides mathematical algorithms and convenience functions built on the NumPy extension of Python.



Interacting With NumPy

Also see NumPy

Indexing

```

a = np.arange(10, dtype=float)
a[0] = 1.0
a[5] = 2.0
a[9] = 3.0
a[1:5] = 4.0
a[5:9] = 5.0
a[9:10] = 6.0
a[10:11] = 7.0
a[11:12] = 8.0
a[12:13] = 9.0
a[13:14] = 10.0
a[14:15] = 11.0
a[15:16] = 12.0
a[16:17] = 13.0
a[17:18] = 14.0
a[18:19] = 15.0
a[19:20] = 16.0
a[20:21] = 17.0
a[21:22] = 18.0
a[22:23] = 19.0
a[23:24] = 20.0
a[24:25] = 21.0
a[25:26] = 22.0
a[26:27] = 23.0
a[27:28] = 24.0
a[28:29] = 25.0
a[29:30] = 26.0
a[30:31] = 27.0
a[31:32] = 28.0
a[32:33] = 29.0
a[33:34] = 30.0
a[34:35] = 31.0
a[35:36] = 32.0
a[36:37] = 33.0
a[37:38] = 34.0
a[38:39] = 35.0
a[39:40] = 36.0
a[40:41] = 37.0
a[41:42] = 38.0
a[42:43] = 39.0
a[43:44] = 40.0
a[44:45] = 41.0
a[45:46] = 42.0
a[46:47] = 43.0
a[47:48] = 44.0
a[48:49] = 45.0
a[49:50] = 46.0
a[50:51] = 47.0
a[51:52] = 48.0
a[52:53] = 49.0
a[53:54] = 50.0
a[54:55] = 51.0
a[55:56] = 52.0
a[56:57] = 53.0
a[57:58] = 54.0
a[58:59] = 55.0
a[59:60] = 56.0
a[60:61] = 57.0
a[61:62] = 58.0
a[62:63] = 59.0
a[63:64] = 60.0
a[64:65] = 61.0
a[65:66] = 62.0
a[66:67] = 63.0
a[67:68] = 64.0
a[68:69] = 65.0
a[69:70] = 66.0
a[70:71] = 67.0
a[71:72] = 68.0
a[72:73] = 69.0
a[73:74] = 70.0
a[74:75] = 71.0
a[75:76] = 72.0
a[76:77] = 73.0
a[77:78] = 74.0
a[78:79] = 75.0
a[79:80] = 76.0
a[80:81] = 77.0
a[81:82] = 78.0
a[82:83] = 79.0
a[83:84] = 80.0
a[84:85] = 81.0
a[85:86] = 82.0
a[86:87] = 83.0
a[87:88] = 84.0
a[88:89] = 85.0
a[89:90] = 86.0
a[90:91] = 87.0
a[91:92] = 88.0
a[92:93] = 89.0
a[93:94] = 90.0
a[94:95] = 91.0
a[95:96] = 92.0
a[96:97] = 93.0
a[97:98] = 94.0
a[98:99] = 95.0
a[99:100] = 96.0
a[100:101] = 97.0
a[101:102] = 98.0
a[102:103] = 99.0
a[103:104] = 100.0
a[104:105] = 101.0
a[105:106] = 102.0
a[106:107] = 103.0
a[107:108] = 104.0
a[108:109] = 105.0
a[109:110] = 106.0
a[110:111] = 107.0
a[111:112] = 108.0
a[112:113] = 109.0
a[113:114] = 110.0
a[114:115] = 111.0
a[115:116] = 112.0
a[116:117] = 113.0
a[117:118] = 114.0
a[118:119] = 115.0
a[119:120] = 116.0
a[120:121] = 117.0
a[121:122] = 118.0
a[122:123] = 119.0
a[123:124] = 120.0
a[124:125] = 121.0
a[125:126] = 122.0
a[126:127] = 123.0
a[127:128] = 124.0
a[128:129] = 125.0
a[129:130] = 126.0
a[130:131] = 127.0
a[131:132] = 128.0
a[132:133] = 129.0
a[133:134] = 130.0
a[134:135] = 131.0
a[135:136] = 132.0
a[136:137] = 133.0
a[137:138] = 134.0
a[138:139] = 135.0
a[139:140] = 136.0
a[140:141] = 137.0
a[141:142] = 138.0
a[142:143] = 139.0
a[143:144] = 140.0
a[144:145] = 141.0
a[145:146] = 142.0
a[146:147] = 143.0
a[147:148] = 144.0
a[148:149] = 145.0
a[149:150] = 146.0
a[150:151] = 147.0
a[151:152] = 148.0
a[152:153] = 149.0
a[153:154] = 150.0
a[154:155] = 151.0
a[155:156] = 152.0
a[156:157] = 153.0
a[157:158] = 154.0
a[158:159] = 155.0
a[159:160] = 156.0
a[160:161] = 157.0
a[161:162] = 158.0
a[162:163] = 159.0
a[163:164] = 160.0
a[164:165] = 161.0
a[165:166] = 162.0
a[166:167] = 163.0
a[167:168] = 164.0
a[168:169] = 165.0
a[169:170] = 166.0
a[170:171] = 167.0
a[171:172] = 168.0
a[172:173] = 169.0
a[173:174] = 170.0
a[174:175] = 171.0
a[175:176] = 172.0
a[176:177] = 173.0
a[177:178] = 174.0
a[178:179] = 175.0
a[179:180] = 176.0
a[180:181] = 177.0
a[181:182] = 178.0
a[182:183] = 179.0
a[183:184] = 180.0
a[184:185] = 181.0
a[185:186] = 182.0
a[186:187] = 183.0
a[187:188] = 184.0
a[188:189] = 185.0
a[189:190] = 186.0
a[190:191] = 187.0
a[191:192] = 188.0
a[192:193] = 189.0
a[193:194] = 190.0
a[194:195] = 191.0
a[195:196] = 192.0
a[196:197] = 193.0
a[197:198] = 194.0
a[198:199] = 195.0
a[199:200] = 196.0
a[200:201] = 197.0
a[201:202] = 198.0
a[202:203] = 199.0
a[203:204] = 200.0
a[204:205] = 201.0
a[205:206] = 202.0
a[206:207] = 203.0
a[207:208] = 204.0
a[208:209] = 205.0
a[209:210] = 206.0
a[210:211] = 207.0
a[211:212] = 208.0
a[212:213] = 209.0
a[213:214] = 210.0
a[214:215] = 211.0
a[215:216] = 212.0
a[216:217] = 213.0
a[217:218] = 214.0
a[218:219] = 215.0
a[219:220] = 216.0
a[220:221] = 217.0
a[221:222] = 218.0
a[222:223] = 219.0
a[223:224] = 220.0
a[224:225] = 221.0
a[225:226] = 222.0
a[226:227] = 223.0
a[227:228] = 224.0
a[228:229] = 225.0
a[229:230] = 226.0
a[230:231] = 227.0
a[231:232] = 228.0
a[232:233] = 229.0
a[233:234] = 230.0
a[234:235] = 231.0
a[235:236] = 232.0
a[236:237] = 233.0
a[237:238] = 234.0
a[238:239] = 235.0
a[239:240] = 236.0
a[240:241] = 237.0
a[241:242] = 238.0
a[242:243] = 239.0
a[243:244] = 240.0
a[244:245] = 241.0
a[245:246] = 242.0
a[246:247] = 243.0
a[247:248] = 244.0
a[248:249] = 245.0
a[249:250] = 246.0
a[250:251] = 247.0
a[251:252] = 248.0
a[252:253] = 249.0
a[253:254] = 250.0
a[254:255] = 251.0
a[255:256] = 252.0
a[256:257] = 253.0
a[257:258] = 254.0
a[258:259] = 255.0
a[259:260] = 256.0
a[260:261] = 257.0
a[261:262] = 258.0
a[262:263] = 259.0
a[263:264] = 260.0
a[264:265] = 261.0
a[265:266] = 262.0
a[266:267] = 263.0
a[267:268] = 264.0
a[268:269] = 265.0
a[269:270] = 266.0
a[270:271] = 267.0
a[271:272] = 268.0
a[272:273] = 269.0
a[273:274] = 270.0
a[274:275] = 271.0
a[275:276] = 272.0
a[276:277] = 273.0
a[277:278] = 274.0
a[278:279] = 275.0
a[279:280] = 276.0
a[280:281] = 277.0
a[281:282] = 278.0
a[282:283] = 279.0
a[283:284] = 280.0
a[284:285] = 281.0
a[285:286] = 282.0
a[286:287] = 283.0
a[287:288] = 284.0
a[288:289] = 285.0
a[289:290] = 286.0
a[290:291] = 287.0
a[291:292] = 288.0
a[292:293] = 289.0
a[293:294] = 290.0
a[294:295] = 291.0
a[295:296] = 292.0
a[296:297] = 293.0
a[297:298] = 294.0
a[298:299] = 295.0
a[299:300] = 296.0
a[300:301] = 297.0
a[301:302] = 298.0
a[302:303] = 299.0
a[303:304] = 300.0
a[304:305] = 301.0
a[305:306] = 302.0
a[306:307] = 303.0
a[307:308] = 304.0
a[308:309] = 305.0
a[309:310] = 306.0
a[310:311] = 307.0
a[311:312] = 308.0
a[312:313] = 309.0
a[313:314] = 310.0
a[314:315] = 311.0
a[315:316] = 312.0
a[316:317] = 313.0
a[317:318] = 314.0
a[318:319] = 315.0
a[319:320] = 316.0
a[320:321] = 317.0
a[321:322] = 318.0
a[322:323] = 319.0
a[323:324] = 320.0
a[324:325] = 321.0
a[325:326] = 322.0
a[326:327] = 323.0
a[327:328] = 324.0
a[328:329] = 325.0
a[329:330] = 326.0
a[330:331] = 327.0
a[331:332] = 328.0
a[332:333] = 329.0
a[333:334] = 330.0
a[334:335] = 331.0
a[335:336] = 332.0
a[336:337] = 333.0
a[337:338] = 334.0
a[338:339] = 335.0
a[339:340] = 336.0
a[340:341] = 337.0
a[341:342] = 338.0
a[342:343] = 339.0
a[343:344] = 340.0
a[344:345] = 341.0
a[345:346] = 342.0
a[346:347] = 343.0
a[347:348] = 344.0
a[348:349] = 345.0
a[349:350] = 346.0
a[350:351] = 347.0
a[351:352] = 348.0
a[352:353] = 349.0
a[353:354] = 350.0
a[354:355] = 351.0
a[355:356] = 352.0
a[356:357] = 353.0
a[357:358] = 354.0
a[358:359] = 355.0
a[359:360] = 356.0
a[360:361] = 357.0
a[361:362] = 358.0
a[362:363] = 359.0
a[363:364] = 360.0
a[364:365] = 361.0
a[365:366] = 362.0
a[366:367] = 363.0
a[367:368] = 364.0
a[368:369] = 365.0
a[369:370] = 366.0
a[370:371] = 367.0
a[371:372] = 368.0
a[372:373] = 369.0
a[373:374] = 370.0
a[374:375] = 371.0
a[375:376] = 372.0
a[376:377] = 373.0
a[377:378] = 374.0
a[378:379] = 375.0
a[379:380] = 376.0
a[380:381] = 377.0
a[381:382] = 378.0
a[382:383] = 379.0
a[383:384] = 380.0
a[384:385] = 381.0
a[385:386] = 382.0
a[386:387] = 383.0
a[387:388] = 384.0
a[388:389] = 385.0
a[389:390] = 386.0
a[390:391] = 387.0
a[391:392] = 388.0
a[392:393] = 389.0
a[393:394] = 390.0
a[394:395] = 391.0
a[395:396] = 392.0
a[396:397] = 393.0
a[397:398] = 394.0
a[398:399] = 395.0
a[399:400] = 396.0
a[400:401] = 397.0
a[401:402] = 398.0
a[402:403] = 399.0
a[403:404] = 400.0
a[404:405] = 401.0
a[405:406] = 402.0
a[406:407] = 403.0
a[407:408] = 404.0
a[408:409] = 405.0
a[409:410] = 406.0
a[410:411] = 407.0
a[411:412] = 408.0
a[412:413] = 409.0
a[413:414] = 410.0
a[414:415] = 411.0
a[415:416] = 412.0
a[416:417] = 413.0
a[417:418] = 414.0
a[418:419] = 415.0
a[419:420] = 416.0
a[420:421] = 417.0
a[421:422] = 418.0
a[422:423] = 419.0
a[423:424] = 420.0
a[424:425] = 421.0
a[425:426] = 422.0
a[426:427] = 423.0
a[427:428] = 424.0
a[428:429] = 425.0
a[429:430] = 426.0
a[430:431] = 427.0
a[431:432] = 428.0
a[432:433] = 429.0
a[433:434] = 430.0
a[434:435] = 431.0
a[435:436] = 432.0
a[436:437] = 433.0
a[437:438] = 434.0
a[438:439] = 435.0
a[439:440] = 436.0
a[440:441] = 437.0
a[441:442] = 438.0
a[442:443] = 439.0
a[443:444] = 440.0
a[444:445] = 441.0
a[445:446] = 442.0
a[446:447] = 443.0
a[447:448] = 444.0
a[448:449] = 445.0
a[449:450] = 446.0
a[450:451] = 447.0
a[451:452] = 448.0
a[452:453] = 449.0
a[453:454] = 450.0
a[454:455] = 451.0
a[455:456] = 452.0
a[456:457] = 453.0
a[457:458] = 454.0
a[458:459] = 455.0
a[459:460] = 456.0
a[460:461] = 457.0
a[461:462] = 458.0
a[462:463] = 459.0
a[463:464] = 460.0
a[464:465] = 461.0
a[465:466] = 462.0
a[466:467] = 463.0
a[467:468] = 464.0
a[468:469] = 465.0
a[469:470] = 466.0
a[470:471] = 467.0
a[471:472] = 468.0
a[472:473] = 469.0
a[473:474] = 470.0
a[474:475] = 471.0
a[475:476] = 472.0
a[476:477] = 473.0
a[477:478] = 474.0
a[478:479] = 475.0
a[479:480] = 476.0
a[480:481] = 477.0
a[481:482] = 478.0
a[482:483] = 479.0
a[483:484] = 480.0
a[484:485] = 481.0
a[485:486] = 482.0
a[486:487] = 483.0
a[487:488] = 484.0
a[488:489] = 485.0
a[489:490] = 486.0
a[490:491] = 487.0
a[491:492] = 488.0
a[492:493] = 489.0
a[493:494] = 490.0
a[494:495] = 491.0
a[495:496] = 492.0
a[496:497] = 493.0
a[497:498] = 494.0
a[498:499] = 495.0
a[499:500] = 496.0
a[500:501] = 497.0
a[501:502] = 498.0
a[502:503] = 499.0
a[503:504] = 500.0
a[504:505] = 501.0
a[505:506] = 502.0
a[506:507] = 503.0
a[507:508] = 504.0
a[508:509] = 505.0
a[509:510] = 506.0
a[510:511] = 507.0
a[511:512] = 508.0
a[512:513] = 509.0
a[513:514] = 510.0
a[514:515] = 511.0
a[515:516] = 512.0
a[516:517] = 513.0
a[517:518] = 514.0
a[518:519] = 515.0
a[519:520] = 516.0
a[520:521] = 517.0
a[521:522] = 518.0
a[522:523] = 519.0
a[523:524] = 520.0
a[524:525] = 521.0
a[525:526] = 522.0
a[526:527] = 523.0
a[527:528] = 524.0
a[528:529] = 525.0
a[529:530] = 526.0
a[530:531] = 527.0
a[531:532] = 528.0
a[532:533] = 529.0
a[533:534] = 530.0
a[534:535] = 531.0
a[535:536] = 532.0
a[536:537] = 533.0
a[537:538] = 534.0
a[538:539] = 535.0
a[539:540] = 536.0
a[540:541] = 537.0
a[541:542] = 538.0
a[542:543] = 539.0
a[543:544] = 540.0
a[544:545] = 541.0
a[545:546] = 542.0
a[546:547] = 543.0
a[547:548] = 544.0
a[548:549] = 545.0
a[549:550] = 546.0
a[550:551] = 547.0
a[551:552] = 548.0
a[552:553] = 549.0
a[553:554] = 550.0
a[554:555] = 551.0
a[555:556] = 552.0
a[556:557] = 553.0
a[557:558] = 554.0
a[558:559] = 555.0
a[559:560] = 556.0
a[560:561] = 557.0
a[561:562] = 558.0
a[562:563] = 559.0
a[563:564] = 560.0
a[564:565] = 561.0
a[565:566] = 562.0
a[566:567] = 563.0
a[567:568] = 564.0
a[568:569] = 565.0
a[569:570] = 566.0
a[570:571] = 567.0
a[571:572] = 568.0
a[572:573] = 569.0
a[573:574] = 570.0
a[574:575] = 571.0
a[575:576] = 572.0
a[576:577] = 573.0
a[577:578] = 574.0
a[578:579] = 575.0
a[579:580] = 576.0
a[580:581] = 577.0
a[581:582] = 578.0
a[582:583] = 579.0
a[583:584] = 580.0
a[584:585] = 581.0
a[585:586] = 582.0
a[586:587] = 583.0
a[587:588] = 584.0
a[588:589] = 585.0
a[589:590] = 586.0
a[590:591] = 587.0
a[591:592] = 588.0
a[592:593] = 589.0
a[593:594] = 590.0
a[594:595] = 591.0
a[595:596] = 592.0
a[596:597] = 593.0
a[597:598] = 594.0
a[598:599] = 595.0
a[599:600] = 596.0
a[600:601] = 597.0
a[601:602] = 598.0
a[602:603] = 599.0
a[603:604] = 600.0
a[604:605] = 601.0
a[605:606] = 602.0
a[606:607] = 603.0
a[607:608] = 604.0
a[608:609] = 605.0
a[609:610] = 606.0
a[610:611] = 607.0
a[611:612] = 608.0
a[612:613] = 609.0
a[613:614] = 610.0
a[614:615] = 611.0
a[615:616] = 612.0
a[616:617] = 613.0
a[617:618] = 614.0
a[618:619] = 615.0
a[619:620] = 616.0
a[620:621] = 617.0
a[621:622] = 618.0
a[622:623] = 619.0
a[623:624] = 620.0
a[624:625] = 621.0
a[625:626] = 622.0
a[626:627] = 623.0
a[627:628] = 624.0
a[628:629] = 625.0
a[629:630] = 626.0
a[630:631] = 627.0
a[631:632] = 628.0
a[632:633] = 629.0
a[633:634] = 630.0
a[634:635] = 631.0
a[635:636] = 632.0
a[636:637] = 633.0
a[637:638] = 634.0
a[638:639] = 635.0
a[639:640] = 636.0
a[640:641] = 637.0
a[641:642] = 638.0
a[642:643] = 639.0
a[643:644] = 640.0
a[644:645] = 641.0
a[645:646] = 642.0
a[646:647] = 643.0
a[647:648] = 644.0
a[648:649] = 645.0
a[649:650] = 646.0
a[650:651] = 647.0
a[651:652] = 648.0
a[652:653] = 649.0
a[653:654] = 650.0
a[654:655] = 651.0
a[655:656] = 652.0
a[656:657] = 653.0
a[657:658] = 654.0
a[658:659] = 655.0
a[659:660] = 656.0
a[660:661] = 657.0
a[661:662] = 658.0
a[662:663] = 659.0
a[663:664] = 660.0
a[664:665] = 661.0
a[665:666] = 662.0
a[666:667] = 663.0
a[667:668] = 664.0
a[668:669] = 665.0
a[669:670] = 666.0
a[670:671] = 667.0
a[671:672] = 668.0
a[672:673] = 669.0
a[673:674] = 670.0
a[674:675] = 6
```



Introdução ao Numpy e Scipy


Demo - Introduction to Numpy/Scipy

Introduction_Numpy_Scipy.ipynb



Introdução ao Matplotlib

- Biblioteca mais popular do Python para visualização de dados
- Grande variedade de gráficos
- Liberdade para editar diferentes aspectos da figura



Cheat Sheet Matplotlib



Python For Data Science Cheat Sheet
Matplotlib

Learn Python Interactively at www.datacamp.com

Matplotlib
Matplotlib is a Python 2D plotting library which produces publication-quality figures in a variety of hardcopy formats and interactive environments across platforms.

1 Prepare The Data [Access Lists & NumPy](#)

1D Data

```
100 import numpy as np
101 m = np.linspace(0, 10, 100)
102 y = np.sin(m)
103 ax = plt.gca()
```

2D Data

```
200 data = {'x': np.random.randn(100), 'y': np.random.randn(100)}
201 x = data['x']
202 y = data['y']
203 ax = plt.gca()
204 ax.scatter(x, y)
```

2 Create Plot

Figure

```
300 fig = plt.figure()
301 ax = fig.gca()
```

3 Plotting Routines

1D Data

```
400 fig, ax = plt.subplots(1)
401 ax.plot(m, y)
```

2D Data or Images

```
500 fig, ax = plt.subplots(2, 1)
501 ax.imshow(data['x'].ravel())
```

4 Customize Plot

Colors, Color Bars & Color Maps

```
600 plt.plot(m, y, color='r', lw=2)
601 plt.plot(m, y, color='b', lw=2)
602 plt.plot(m, y, color='g', lw=2)
603 plt.plot(m, y, color='r', lw=2)
```

Markers

```
700 plt.plot(m, y, marker='o')
701 plt.plot(m, y, marker='x')
```

Grids & Annotations

```
800 plt.grid(True)
801 plt.annotate('Peak', xy=(5, 0.5))
802 plt.annotate('Trough', xy=(5, -0.5))
```

5 Save Plot

```
900 fig.savefig('plot.png')
```

6 Show Plot

```
1000 plt.show()
```

Close & Clear

```
1100 plt.close()
```

Plot Anatomy & Workflow

Plot Anatomy

Workflow

The basic steps to creating plots with matplotlib are:

- 1 Prepare data
- 2 Create plot
- 3 Plot
- 4 Customize plot
- 5 Save plot
- 6 Show plot

1 Prepare data

```
100 import numpy as np
101 m = np.linspace(0, 10, 100)
102 y = np.sin(m)
103 ax = plt.gca()
104 ax.scatter(m, y)
```

2 Create plot

```
200 fig = plt.figure()
201 ax = fig.gca()
```

3 Plot

```
300 ax.plot(m, y)
```

4 Customize plot

```
400 ax.plot(m, y, color='r', lw=2)
401 ax.plot(m, y, color='b', lw=2)
402 ax.plot(m, y, color='g', lw=2)
403 ax.plot(m, y, color='r', lw=2)
```

5 Save plot

```
500 fig.savefig('plot.png')
```

6 Show plot

```
600 plt.show()
```

Close & Clear

```
700 plt.close()
```

Figura: Cheat Sheet de funções da Matplotlib¹⁵.

¹⁵ <http://datacamp-community.s3.amazonaws.com/28b8210c-60cc-4f13-b0b4-5b4f2ad4790b>



Introdução ao Matplotlib

Demo - Introduction to Matplotlib

Introduction_Matplotlib.ipynb



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



Extração de Features

- Antes de Deep Learning, extração de features era necessária para lidar com **dados não estruturados**
- Features boas são desenhadas visando realçar e compactar as propriedades importantes do objeto
 - É difícil saber quais propriedades são importantes para o domínio e a tarefa em mãos
- Diferentes domínios possuem diferentes tipos de features



Extração de Features

- Alguns domínios possuem features naturais
 - Informações de prontuário médico (i.e. idade, sexo, peso, presença/ausência de sintomas etc)
 - Mercado imobiliário (i.e. bairro, andar, número de quartos, número de banheiros etc)
- Outros domínios precisam de algoritmos de extração de features
 - Imagens (i.e. forma, textura, cor etc)
 - Sinais Temporais (i.e. densidade espectral, frequências mais importantes, amplitude média etc)



Tipos de Features

- Features Categóricas
 - Possui divisão bem definida entre categorias (i.e. bairro – Ouro Preto/Liberdade/Savassi/Lourdes, tipo – apartamento/casa/kitnet, cozinha – s/n, cor – branca/amarela/azul/verde, piscina – s/n etc)
- Features Numéricas
 - Valores contínuos ou discretos que possuem uma relação numérica com valores próximos (i.e. andar, número de quartos, metros quadrados, número de banheiros etc)



Extração de Features em Texto

"Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum."

- Que características parecem relevantes em um conteúdo textual?



Extração de Features em Texto

“Essa é uma frase contendo diferentes flexões gramaticais!”

- Tokenização e filtragem

- {“Essa”, “é”, “uma”, “frase”, “contendo”, “diferentes”, “flexões”, “gramaticais” }
- Dependendo do contexto, algumas palavras são descartadas no processo de filtragem. Essas são as chamadas *stop words*.

- Lematização (opcional)

- { “Essa”, “ser”, “uma”, “frase”, “conter”, “diferente”, “flexão”, “gramatical” }



Extração de Features em Texto

- Dicionários (Bag of Words)
 - A cada palavra é atribuído um valor inteiro (0, 1, 2, 3...)
 - Palavras com códigos próximos não necessariamente possuem significados/propriedades próximas
 - As features mais comuns são compostas das frequências dos termos



Extração de Features em Texto

"Nesse exemplo, a ordem das palavras depende da frequência que cada palavra aparece."

ID	String	Frequência
0	palavra	2
1	da	2
2	ordem	1
...	...	...
N	cada	1



Extração de Features em Texto

- Term-Frequency (TF)
 - Contar as ocorrências de cada palavra em valor absoluto seria fortemente impactado pelo tamanho do texto.
 - Atribui-se portanto um peso intitulado frequência do termo, que pode ser dado por $t_f = \frac{count_w}{N}$, sendo N o número total de palavras do texto, e $count_w$ o número de ocorrências da palavra.
 - Dessa forma a frequência de palavras é dada de forma relativa **a cada documento**.



Extração de Features em Texto

- Term-Frequency – Inverse Document-Frequency (TF-IDF)
 - Para refinar o peso dado pela frequência de termos t_f , é levado em consideração a frequência das palavras ao longo de **todos os documentos**.
 - Palavras muito comuns trazem pouca informação ao texto (i.e. “e”, “a”, “o”, “um”, “uma”, “de”, “que” etc)
 - Ambos os fatores compõe uma feature de texto amplamente utilizada chamada TF-IDF.



Extração de Features em Texto

- Scikit-learn

From text

The `sklearn.feature_extraction.text` submodule gathers utilities to build feature vectors from text documents.

<code>feature_extraction.text.CountVectorizer</code> ([...])	Convert a collection of text documents to a matrix of token counts
<code>feature_extraction.text.HashingVectorizer</code> ([...])	Convert a collection of text documents to a matrix of token occurrences
<code>feature_extraction.text.TfidfTransformer</code> ([...])	Transform a count matrix to a normalized tf or tf-idf representation
<code>feature_extraction.text.TfidfVectorizer</code> ([...])	Convert a collection of raw documents to a matrix of TF-IDF features.

Extração de Features em Imagens



- Imagens possuem muita redundância entre pixels vizinhos
- Como se livrar da informação redundante e extrair apenas as características mais importantes?



Extração de Features em Imagens

- Algumas categorias principais de features em imagens
 - Bordas
 - Frequência
 - Cor
 - Textura
 - Forma
- Diferentes domínios da área de Visão Computacional usam diferentes combinações desses features
- Dependendo da tarefa, os features podem ser extraídos da imagem toda (features globais) ou de patches (features locais)

Extração de Features em Imagens



- Bordas
 - Canny
 - Sobel
 - Prewitt
 - Laplace



Extração de Features em Imagens

- Frequências
 - Wavelets
 - Discrete Fourier Transform (DFT)
 - Discrete Cosine Transform (DCT)
 - Spectral Density



Extração de Features em Imagens

- Features de Cor
 - Global Color Histogram (GCH)
 - Color Coherent Vector (CCV)
 - Border/Interior Pixel Classification (BIC)
 - Color-Based Clustering (CBC)



Extração de Features em Imagens

- Features de Textura
 - Gray-Level Co-occurrence Matrix (GLCM)
 - Local Binary Patterns (LBP)
 - Wavelets
 - Homogeneous Texture Descriptor (HTD)
 - Quantized Compound Change Histogram (QCCH)



Extração de Features em Imagens

- Features de Forma
 - Histogram of Oriented Gradients (HOG)
 - Wavelets
 - Scale-Invariant Feature Transform (SIFT)
 - Speeded Up Robust Features (SURF)
 - Shape Index
 - Extended Morphological Profiles (EMP)



Extração de Features em Imagens

- A maioria dos features codifica informações com mais de uma semântica
 - BIC codifica informação tanto de cor quanto de textura
 - Wavelets codificam tanto informação de textura quanto de frequência
 - SIFT codifica tanto informação de textura quanto de forma



Features em Imagens

Demo - Image Features

Image_Features.ipynb



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



Aplicações de Machine Learning




Figura: Aplicações de Machine Learning.



Aplicações de Machine Learning




Figura: Aplicações de Machine Learning.



Aplicações de Machine Learning




Figura: Aplicações de Machine Learning.



Aplicações de Machine Learning



Figura: Aplicações de Machine Learning.



Aplicações de Machine Learning




Figura: Aplicações de Machine Learning.

Shallow Learning



- Abordagem clássica para a aprendizagem de máquina
- Modelos estatísticos para o reconhecimento automático de padrões
- Usa algoritmos de extração de características como pré-processamento



Shallow Learning




Figura: Pipeline padrão de um algoritmo de Machine Learning clássico.



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



Seleção de Modelos




Figura: Qual fronteira de decisão escolher dentre todas as possíveis?



Seleção de Modelos




Figura: Qual fronteira de decisão escolher dentre todas as possíveis? Essa fronteira é generalista o bastante?



Seleção de Modelos




Figura: Qual fronteira de decisão escolher dentre todas as possíveis?



Seleção de Modelos




Figura: Qual fronteira de decisão escolher dentre todas as possíveis?

Seleção de Modelos



- Esse exemplo nos faz ponderar sobre a real natureza de Machine Learning
 - Inferência sobre um conjunto de dados limitado é um problema complexo
 - Não há um único modelo a ser otimizado

Machine Learning



Suposições dos Modelos de Learning

Quantas e quais suposições fazer?



Número de Parâmetros



Poucos parâmetros

Muitos parâmetros

Figura: Trade-off do número de parâmetros de um modelo.



Número de Parâmetros




Figura: Trade-off do número de parâmetros de um modelo.



Número de Parâmetros




Figura: Trade-off do número de parâmetros de um modelo.



Número de Parâmetros




Figura: Número de parâmetros vs. número de amostras.



Número de Parâmetros




Figura: Número de parâmetros vs. número de amostras.



Número de Parâmetros




Figura: Número de parâmetros vs. número de amostras.



Número de Parâmetros




Figura: Número de parâmetros vs. número de amostras.



Número de Parâmetros




Figura: Número de parâmetros vs. número de amostras.



Número de Parâmetros




Figura: Número de parâmetros vs. número de amostras.



Número de Parâmetros




Figura: Conjunto de 13 pontos a serem fitados.



Número de Parâmetros




Figura: Fit com um polinômio de 12º.



Número de Parâmetros






Figura: Fit com um polinômio de 1^o.



Número de Parâmetros



(a) Polinômio de 1º grau.



(b) Polinômio de 12º graus.

Figura: Exemplos de fits de curvas polinomiais.



Número de Parâmetros




Figura: Exemplo de modelo overfitado (alta variância).



Número de Parâmetros




Figura: Conjunto de pontos a serem fitados.



Número de Parâmetros




Figura: Fit com um polinômio de 1º grau.



Número de Parâmetros






Figura: Fit com um polinômio de 2º grau.



Número de Parâmetros



(a) Polinômio de 1º grau.



(b) Polinômio de 2º grau.

Figura: Exemplos de fits de curvas polinomiais.



Número de Parâmetros




Figura: Exemplo de modelo underfitado (alto viés).



Número de Parâmetros

- Sempre é possível com N samples fitar um polinômio de grau $(N-1)$ que passe exatamente pelos pontos
- Como escolher o grau do polinômio?
 - $y = a.x + b$
 - $y = a.x^2 + b.x + c$
 - $y = a.x^3 + b.x^2 + c.x + d$



Número de Parâmetros

Número de Parâmetros de um modelo

Em Machine Learning, apesar da maioria dos modelos não serem polinomiais, existe esse mesmo trade-off entre viés e variância. Por um lado, um modelo com poucos parâmetros pode ser **simples demais** para modelar os padrões dos dados; por outro lado, um modelo complexo demais consegue memorizar todas as variações do conjunto de treino, falhando em capturar os **padrões realmente importantes** dos dados.



Fit Polinomial

Demo - Polynomial Fit

Poly_Fit.ipynb



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



Mapa de Métodos




Figura: Mapa do scikit-learn¹⁶ indicando os métodos indicados para cada tipo de problema.

¹⁶ http://scikit-learn.org/stable/tutorial/machine_learning_map/index.html




Tipos de Rotulação


- Algoritmos Não-Supervisionados
 - Nenhum rótulo
- Algoritmos Fracamente Supervisionados
 - Poucas amostras rotuladas e muitas não rotuladas
- Algoritmos Semi-Supervisionados
 - Amostras rotuladas e não rotuladas
- Algoritmos Supervisionados
 - Amostras rotuladas




Tipos de Rotulação




(a) Não-Supervisionado



(b) Fracamente Supervisionado



(c) Semi-Supervisionado



(d) Supervisionado

Figura: Algoritmos de acordo com os tipos de rotulação.




Tipos de Modelagem


- Modelos Generativos
 - Modelam a distribuição que gerou os dados
- Modelos Discriminativos
 - Modelam fronteiras de decisão entre diferentes classes



Tipos de Modelagem



(a) Modelo Discriminativo



(b) Modelo Generativo

Figura: Tipos de Modelagem.




Tipos de Tarefas

- Classificação
 - Predizem classes
- Regressão
 - Predizem valores numéricos
- Clusterização
 - Acham os clusters naturais presentes no conjunto de dados
- Redução de Dimensionalidade
 - Diminuem a dimensionalidade de dados para propósitos de análise ou visualização por humanos




Tipos de Tarefas



(a) Classificação

(b) Regressão

(c) Clusterização



(d) Redução de Dimensionalidade

Figura: Algoritmos de acordo com os tipos de tarefas.



Notas sobre os Slides

Notas sobre os Slides

Algumas das figuras usadas na seção a seguir sobre algoritmos de classificação foram adaptadas de outros conjuntos de slides. Mais especificamente, foram usados materiais do Prof. Jefersson Santos (DCC/UFGM), Prof. Alexander Ihler (UC/Irvine) e Prof. Ethem Alpaydin (Bogaziçi University).

Classificação



- Separação de amostras em classes
- Requer **dados rotulados**
- Otimização de uma fronteira de decisão



Overfitting em um Classificador




Figura: Overfitting em um classificador.

Algoritmos de Classificação



- K Nearest Neighbors (KNN)
- Decision Trees (DT)
- Random Forest (RF)
- Support Vector Machine (SVM)
- AdaBoost



K Nearest Neighbors




Figura: Exemplo de KNN.



K Nearest Neighbors




Figura: Exemplo de KNN.



K Nearest Neighbors




Figura: Exemplo de KNN.



K Nearest Neighbors




Figura: Exemplo de KNN.



K Nearest Neighbors




Figura: Exemplo de KNN.



K Nearest Neighbors




Figura: Exemplo de KNN.



K Nearest Neighbors

- Vantagens

- Não possui etapa de treinamento
- Processo de teste extremamente simples (distância euclidiana)
- Poucos hiperparâmetros a serem otimizados

- Desvantagens

- Todas as amostras são salvas no modelo
- Para o teste, uma busca deve ser feita com complexidade $\Theta(N)$
- Problemas com generalização e *outliers*

KNN




Demo - KNN

KNN.ipynb

Decision Trees



- Naturalmente hierárquico
- Computacionalmente barato
- Algoritmo recursivo simples de se implementar



101/128



Exemplo de Decision Tree




Figura: Exemplo de Decision Tree.



Exemplo de Decision Tree





Figura: Exemplo de Decision Tree.



Exemplo de Decision Tree




Figura: Exemplo de Decision Tree.



Exemplo de Decision Tree




Figura: Exemplo de Decision Tree.



Decision Trees

Complexidade em Decision Trees

É possível **enviesar** o modelo controlando a altura máxima da árvore.



Controlando a Complexidade das DTs




Figura: Complexidade das DTs.

Decision Trees



- Early Stop é normalmente utilizado para evitar overfit
 - Caso o modelo não seja impedido de crescer, ruído nos dados facilmente gera overfit
 - Um modelo é considerado bom e para de crescer quando os nós atingem um certo grau de pureza

Decision Trees



Pureza de Nós em uma Decision Tree

Como medir pureza nos nós de uma Decision Tree?



Decision Trees




Figura: Pureza nos nós de uma Decision Tree.



Decision Trees




Figura: Pureza nos nós de uma Decision Tree.

- Classe vermelha: $\frac{5}{7} \approx 0.71$
- Classe azul: $\frac{2}{7} \approx 0.29$



Decision Trees




Figura: Pureza nos nós de uma Decision Tree.

- Gini: $G(p) = 1 - \sum_{i=1}^J p_i^2$
- Entropia: $H(p) = -\sum_{i=1}^J p_i \log_2 p_i$

Decision Trees



Atividade Prática - Overfit/Underfit em KNNs e Decision Trees

KNN_and_Decision_Trees.ipynb



Support Vector Machines

- Boa capacidade de generalização (maximização da margem)
- Robusto para dados com muitas dimensões
- Forte background matemático
- Possibilidade do uso de kernels
- Modelo bastante compacto após treinamento



Support Vector Machines




Figura: Classificação usando Support Vector Machines.



Support Vector Machines




Figura: Classificação usando Support Vector Machines.



Support Vector Machines




Figura: Classificação usando Support Vector Machines.



Support Vector Machines




Figura: Classificação usando Support Vector Machines.



Support Vector Machines




Figura: Classificação usando Support Vector Machines.



Kernels em Support Vector Machines

- Muitas vezes os dados de treinamento não são linearmente separáveis
- SVMs pertencem a um conjunto de algoritmos que podem contar com o uso de kernels
- Várias funções diferentes podem servir como kernels
 - Funções Polinomiais
 - Radial Basis Function (RBF)
 - Tangente Hiperbólica (tanh)



Kernels




Figura: Kernels em Support Vector Machines.



Kernels




Figura: Kernels em Support Vector Machines.



Kernels




Figura: Kernels em Support Vector Machines.



Kernels




Figura: Kernels em Support Vector Machines.



SVM Kernels

Demo - SVM Kernels

SVM_Kernels.ipynb



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network

Avaliação de Modelos



Avaliação de Modelos

Como garantir que meu modelo está com um bom trade-off entre viés e variância?

Avaliação de Modelos



- É preciso quantificar a quantidade de erros de predição que o modelo de inferência gerou
- Métricas de erro

Avaliação de Modelos



- Métricas para problemas de **Classificação**
 - Acurácia
 - F1 (Dice) score
 - Intersection Over Union (Jaccard)
 - Precision
 - Recall

Avaliação de Modelos



- Métricas para problemas de **Regressão**
 - Variância Explicada
 - R^2
 - Mean Squared Error (MSE)
 - PSNR (processamento de sinais/imagens)

Avaliação de Modelos



- Métricas para problemas de Clusterização
 - Homogeneidade
 - Informação Mútua
 - Completude



Protocolos de Avaliação

- Conjuntos de Dados
 - Conjunto de Treino
 - Usado para treinar os modelos
 - Conjunto de Teste
 - Usado para avaliar o modelo



Protocolos de Avaliação




Figura: Divisão entre Treino e Teste.




Figura: Erro vs. #Params.



Protocolos de Avaliação

- Conjuntos de Dados
 - Conjunto de Treino
 - Usado para treinar os modelos
 - Conjunto de Teste
 - Usado para avaliar os modelos
 - Conjunto de Validação
 - Usado para tunar os parâmetros dos modelos aos dados



Protocolos de Avaliação




Figura: Divisão entre Treino, Validação e Teste.




Figura: Erro vs. #Params.

Protocolo de Avaliação



Exercício - Full Protocol

Full_Protocol.ipynb



Agenda

1 Introdução

- Boas-vindas
- Introdução a Deep Learning
- Ambiente

2 Introdução a Python

3 Extração de Features

4 Shallow Learning

- Fundamentos do Aprendizado de Máquina
- Algoritmos de Aprendizado de Máquina
- Avaliação de Modelos

5 Demonstração de Neural Network



MultiLayer Perceptron (MLP)

Demo - MultiLayer Perceptron (MLP)

MLP.ipynb

- [1] NVIDIA.
Deep learning - nvidia developer, 2018.
- [2] Ian Goodfellow, Yoshua Bengio, Aaron Courville, and Yoshua Bengio.
Deep learning, volume 1.
MIT press Cambridge, 2016.

